

编程过程中具体碰到的问题和处理

项目：I3DM，长视频三维一致生成。平台配额：1 张 A100，4 核，单作业 4 小时。

下面按时间写这次实际卡住的地方。每一条都是：当时看到什么，我先怀疑什么，最后改了哪里。网络结构用的是官方代码，改动集中在环境、数据、评测怎么续跑，以及训练时的帧数。



推理跑通之后的一条结果：左列生成，右列真值。一共完成 32 个场景，这是其中厨房那条。

环境和数据

1. 平台上的 5090 用不成

卡住的地方。机器里有 RTX 5090 和 A100。一开始装的 torch 2.4.1 不支持 5090（计算能力 sm₁₂₀）。申请 GPU 时把类型写成小写，作业也会直接拒。

当时怎么想。先确认当前这套 torch 能跑哪张卡，而不是为了用 5090 去改一堆编译依赖。5090 要新的 CUDA 架构，短期对不上。

怎么处理。改成申请 A100，类型名必须写成大写 A100。后来 torch 升到 2.5.0，仍然只用 A100。交互申请的写法是 srun，分区 Students，qos 用本科生默认配额。

2. 数据下不下来

卡住的地方。计算节点访问 huggingface.co 时 curl 返回 000，域名解析失败。国内镜像 hf-mirror 是通的。但网页终端里只要打出 https://，地址会被自动包上一对反引号，手敲、粘贴、甚至在 Python 里拼接字符串都会中招。环境变量因此是坏的，程序又绕回官方站。另外整仓 snapshot_download 内部还会去列官方文件树，同样失败。

当时怎么想。这不是数据集坏了，是命令进终端的方式和下载接口走的路线有问题。要避免键盘输入 URL，也要避免会回连官方站的接口。

怎么处理。把镜像地址写成十六进制，在 Python 里解码后再设 HF_ENDPOINT，这样终端碰不到 https

这几个字。下载改成按文件调用 hf_hub_download，不再用整仓快照。Re10K 的 test 有 543 个打包文件，每个文件里大约十几个场景，index.json 能对上场景和文件。评测用到的场景实际只落在 121 个文件里，就只下这 121

个，比全量少大约四分之三。四个线程一起下，速度从大约每分钟半个文件提到两个文件。解包后是 2930 个场景。

3. 三个库的版本互相卡死

卡住的地方。仓库自带的 requirements 是作者本机 pip freeze 的全量列表。直接安装会在 xformers、triton 这类要编译的包上失败。transformers 新的大版本还要求 torch 至少 2.6，和当时能用的 CUDA 轮子对不上。

当时怎么想。不要试图一次装齐。先找出一组能在 A100 上把模型 import 进来的版本，再停手。

怎么处理。最后锁死的组合是 torch 2.5.0 (cu124)、xformers 0.0.28.post2、transformers 4.57.3。验收不是“安装命令没报错”，而是 WanVideoPipeline 和记忆检索模块都能 import。

评测

4. 第一次冒烟评测，文件明明在，作业说找不到

卡住的地方。单场景评测提交之后失败。数据放在登录节点的 /tmp 里。登录节点能看到，计算节点看不到。当时怎么想。报错像缺文件。先查这两台机器是不是共享这块盘，而不是去改模型加载代码。怎么处理。数据和脚本都改到家目录，登录节点和计算节点都能读。场景 8bd3923459d18567 跑通，大约 13 分 15 秒，产出 6 段视频和拼接结果。还有一个附带问题：metadata 里写的是绝对路径，process_data 生成的目录不能随便移动，移动就要改路径。

5. 四个小时装不下一整批评测

卡住的地方。冒烟测出单场景大约 14 分钟。一块放 16 个场景，时间接近 4 小时上限，再多就会被杀掉。本科生配额同时还限制同时排队的作业数量。原本想跑更多场景，按这个速度排不开。当时怎么想。先用实测时间反推一块能放几个场景，再让作业中途死掉之后不必从头生成。怎么处理。评测脚本里加了一句：如果该场景目录下已经有 video_combined.mp4，就打印跳过并进入下一个。场景列表按大约 16 个一块切开，分别提交。实际跑完前两块（作业 52800 和 52825），后面为了把卡让给训练，多出来的评测作业取消了。最后 32 个场景都有生成视频和真值视频，中间没有失败重跑。

训练

6. 训练依赖每次只爆一个


卡住的地方。评测能跑，不代表训练脚本的依赖齐了。作业 52883 缺 pandas，补上之后 53053 缺 easydict，再补上 53054 又缺 wandb。官方 requirements 没把训练入口真正 import 的包写全。当时怎么想。与其每失败一次装一个包，不如在下次提交前把训练脚本的 import 扫完。怎么处理。pandas 2.3.3、easydict、wandb 0.29.0 一次补齐后再交。后面才进入真正的计算问题。

7. 显存不够，而且第一反应是错的

卡住的地方。依赖齐了以后，作业 53054 在前向时 CUDA out of memory。77 帧、640×352，一次前向大约 78.5 GiB，A100 是 80 GiB，几乎贴顶。当时怎么想。最容易怀疑的是 LoRA。当时 rank 是 1024，权重本身不小。如果原因真是 rank，把它降到 512，显存应该明显下去。所以没有同时改帧数，只改了 rank，这是作业 53055。怎么处理。53055 的显存几乎没变，还是大约 78.5 GiB。这个结果把「LoRA 太大」排除了。视频模型里占显存的大头是激活，激活跟着序列长度走，不跟着 rank 走。于是把数据集里的目标帧数从 77 改成 41。帧数减 1 必须能被 4 整除，VAE 才压得动时间维，41 满足这一点。rank 改回 1024。这次是作业 53057，200 步跑完，大约 12.6 秒一步，42 分钟，四个 checkpoint 都存下来了。

作业	改了什么	结果
53054	依赖刚补齐，77 帧，rank 1024	前向约 78.5 GiB，OOM
53055	只把 rank 降到 512	显存几乎不变，猜测不成立
53057	帧数改成 41，rank 恢复 1024	200 步跑完

降 rank 没有把训练修好。它的用处是失败得很干净：只动一个变量，现象不动，原因就缩小到帧数。



200 步的 loss。蓝线是原始值，红线是滑动平均。扩散训练单步 loss 会随时间步跳动，所以不要求这 200 步画出平滑下降。看的是没有 NaN、梯度还在（大约 2.1）、权重能存下来。

8. 训练日志是离线二进制，曲线拿不出来

卡住的地方。平台上 wandb 只能离线记。网页打不开，日志文件又不是普通文本，直接 tail 看不到每个 step 的 loss。

当时怎么想。200 步本来就不是用来对论文指标的，但得确认数值没有炸。没有曲线就不知道是稳定波动还是已经 NaN。

怎么处理。按 wandb 离线文件的记录格式把 loss 解出来，每 10 步一个点，一共 20 个，范围大约 0.003 到 0.28，没有 NaN。同时核对输出目录里 step 50、100、150、200 四个权重都在。

这些做法在别的问题上也一样

上面是这一次的具体过程。换一个报错，顺序还是这几步，不限于显存。

先让同一个失败再出现一次。复现不了，就先别改代码。然后只猜一个原因，并且事先说好：如果猜对了，改完应该看到什么。这次「rank 太大」就是这样试的，预测是显存下降，实际没下降，猜测就丢掉。

一次只改一处。范围先缩到一层里：是缺包，是两台机器路径不通，是前向显存，还是作业时间被杀掉。小例子确认旧问题没了，再把任务放大。有效配置和失败的作业号记下来，下次不用从头猜。

没有做的部分

网络没有重写。我改的是下载、评测续跑和训练帧数。论文训练是 11000 步，四个小时一轮排不开，所以只做了 200 步，用来确认能反传、能存权重。评测脚本本身不算 FVD 和 PSNR，这次没有另写指标。训练用的文字描述是通用模板，不是论文里的视觉模型打标。